

مشابه اسناد و ادبی سرقت تشخیص موتور فنی: گزارش

Semantic Duplicate & Near-Plagiarism Detection Engine

پروژه کلی معرفی ۱.

پیاده‌سازی مشابه معنایی نظر از و تکراری به نزدیک تکراری، اسناد تشخیص برای فرمان خط موتور یک پروژه این می‌کند.

می‌کند: مقایسه یکدیگر با را اصلی رویکرد دو سامانه

1 Shingling + MinHash + LSH

2 TF-IDF Weighted SimHash

نوت‌بوکی. صرفاً پیاده‌سازی یک نه است؛ بازتولید قابل و مازولار CLI ابزار یک ساخت پروژه هدف

مسئله تعریف ۲.

دارند. یکدیگر با بالایی شباهت که است جفت‌اسنادی یافتن هدف اسناد، از مجموعه‌ای داشتن با

لازم مقایسه‌های تعداد سند، n برای می‌کند. مقایسه دیگر اسناد تمام با را سند هر، (naive) ساده‌لوحانه رویکرد با: است برابر

$$n(n - 1) / 2$$

تقریبی روش‌های از دلیل همین به می‌شود. پرهزینه بسیار محاسباتی نظر از بزرگ اسناد مجموعه برای روش این شباهت اطلاعات حال عین در و یابد کاهش محاسبات تا می‌شود استفاده SimHash و LSH و MinHash مانند حفظ شود.

متن پیش‌پردازش ۳.

می‌شود. تبدیل یکسان‌سازی‌شده نمایش یک به و پاکسازی ابتدا ورودی سند هر

پیاده‌سازی‌شده: پیش‌پردازش مراحل

- یونیکد یکسان‌سازی (Unicode normalization)
- فارسی/عربی حروف یکسان‌سازی
- کوچک حروف به تبدیل (lowercasing)
- HTML تگ‌های حذف
- ایمیل و URL حذف
- نمادها و نشانه‌گذاری حذف
- اضافه فاصله‌های حذف
- کلمه سطح در توکن‌سازی
- (stopwords) توقف واژه‌های حذف
- کلمه‌ای شینگل‌سازی

شینگل: پیش‌فرض اندازه

$$k = 3$$

غیرقابل اعتماد شباهت محاسبه از و می‌کند علامت‌گذاری نامعتبر را سند سامانه خالی، یا کوتاه بسیار اسناد برای می‌کند. پرهیز

۴. کلمه‌ای شینگل‌سازی (Word Shingling)

است. متوالی کلمه k از دنباله‌ای کلمه‌ای، شینگل یک

مثال:

text = "lion ate zebra and goat"

$$k = 2$$

تولیدشده: شینگل‌های

(lion, ate)

(ate, zebra)

(zebra, and)

(and, goat)

کلمات سند دو است ممکن زیرا دارد اهمیت موضوع این می‌کند. حفظ را کلمات محلی ترتیب شینگل‌سازی متفاوت. ترتیب با اما باشند داشته یکسانی

۵. دقیق جاکارد شباهت (Exact Jaccard Similarity)

می‌شود. داده نمایش شینگل‌ها از مجموعه‌ای به صورت سند هر شینگل‌سازی، از پس

با: است برابر جاکارد شباهت A و B شینگل مجموعه دو برای

$$J(A, B) = |A \cap B| / |A \cup B|$$

است. پرهزینه بزرگ، مجموعه یک جفت اسناد همه روی اعمال هنگام اما است دقیق روش این

۶. مین‌هش (MinHash)

می‌کند. تولید فشرده امضای یک سند هر شینگل مجموعه برای MinHash

می‌کند. مقایسه را کوتاه‌تر MinHash امضاهای سامانه شینگل، بزرگ مجموعه‌های مستقیم مقایسه به جای

پیاده‌سازی: این در

$$\text{num_perm} = 128$$

می‌شود. محاسبه آن‌ها امضاهای در برابر موقعیت‌های نسبت از سند دو بین تخمینی شباهت

داخلی hash تابع است. شده پیاده‌سازی (deterministic) قطعی هش توابع از استفاده با و صفر از MinHash می‌شود. تصادفی‌سازی برنامه مختلف اجراهای بین زیرا نشده، استفاده به عمد پایتون

۷. هشینگ سنسیتیو لوکالیتی (LSH)

می‌شود. استفاده زوجی مقایسه‌های تعداد کاهش برای LSH

می‌شود. تقسیم (band) باند چند به MinHash امضای

پیش‌فرض: تنظیم

`num_bands = 32`

می‌شوند. گرفته نظر در کاندید جفت به‌عنوان باشند، مشترک باند یک از (bucket) باکت یک در حداقل سند دو اگر ممکن. جفت‌اسناد تمام روی نه می‌شود، انجام کاندید جفت‌های روی فقط جاکارد دقیق و نهایی مقایسه

۸. TF-IDF با وزن‌دار سیم‌هش

می‌کند. تولید فشرده (fingerprint) اثرانگشت یک سند هر برای SimHash

می‌کند: استفاده زیر موارد از پیاده‌سازی‌شده روش

- کلمه‌ای توکن‌های
- (term frequency) واژه نرمال‌شده فراوانی
- (smoothed IDF) هموارشده معکوس سند فرکانس
- بیتی ۶۴ قطعی هش
- (Hamming distance) همینگ فاصله

پیش‌فرض: تنظیم

`hash_bits = 64`

از نهایی اثرانگشت می‌شود. سهم بیت موقعیت هر در منفی یا مثبت به‌صورت آن TF-IDF وزن توکن، هر برای می‌شود. ساخته بعد هر در انباشته‌شده مقدار علامت روی

می‌شود: محاسبه زیر به‌صورت شباهت

`similarity = 1 - hamming_distance / hash_bits`

۹. دستورهای CLI

می‌دهد. ارائه CLI اصلی دستور سه پروژه

۹.۱ سند دو مقایسه

```
python -m plagiarism_engine.cli compare \  
--file-a data/sample_corpus/doc_01.txt \  
--file-b data/sample_corpus/doc_02.txt \  
--shingle-size 3 \  
--output outputs/two_file_compare.json
```

می‌کند: محاسبه را زیر موارد دستور این

- دقیق جاکارد شباهت
- MinHash شباهت
- SimHash اثرانگشت‌های

- SimHash همینگ فاصله
 - SimHash شباهت
-

۹.۲ مجموعه یک در مشابه اسناد جستجوی

```
python -m plagiarism_engine.cli corpus \  
--data data/sample_corpus \  
--threshold 0.1 \  
--shingle-size 3 \  
--output outputs/candidates.csv
```

می‌کند: استفاده زیر موارد از دستور این

- پیش‌پردازش
- شینگل‌سازی
- MinHash
- LSH
- جاکارد نهایی فیلتر

است. LSH محاسبات کاهش آمار و کاندید جفت‌اسناد شامل خروجی فایل

۹.۳ برچسب‌دار جفت‌های روی ارزیابی

```
python -m plagiarism_engine.cli pairs \  
--pairs data/sample_corpus/sample_pairs.csv \  
--text-col-a text_a \  
--text-col-b text_b \  
--label-col label \  
--threshold 0.1 \  
--simhash-threshold 0.65 \  
--shingle-size 2 \  
--output outputs/metrics.csv
```

می‌کند: محاسبه زیر موارد برای را ارزیابی معیارهای دستور این

- دقیق جاکارد
 - MinHash
 - SimHash
-

۱۰ ارزیابی معیارهای

شده‌اند: پیاده‌سازی زیر معیارهای

- accuracy (دقت کلی)
- precision (دقت)

- recall (بازیابی)
- F1-score
- اجرا زمان (runtime)

تکراری: موارد دودویی تشخیص برای

```
prediction = 1 if similarity >= threshold
prediction = 0 otherwise
```

هستند. تکراری واقعاً تکراری، به عنوان پیش‌بینی شده جفت‌های از درصد چند می‌دهد نشان Precision

شده‌اند. داده تشخیص سامانه توسط تکراری، واقعاً جفت‌های از درصد چند می‌دهد نشان Recall

می‌کند. برقرار توازن recall و precision میان F1-score

دیتاست‌ها ۱۱.

دیتاست یک و، CLI سریع آزمایش برای کوچک دیتاست یک است: شده استفاده پروژه این در جداگانه دیتاست دو تجربی. ارزیابی برای واقعی

۱۱.۱ (Smoke Test) نمونه دیتاست

است: شده داده قرار زیر مسیر در کوچک نمونه دیتاست یک

data/sample_corpus/

است: زیر موارد شامل دیتاست این

- 'corpus' و 'compare' دستورهای (برای نمونه متنی اسناد)
- ('sample_pairs.csv') برچسب‌دار جفت‌های از کوچک CSV فایل یک

کافی آماری حجم و می‌شوند استفاده خروجی‌ها بازتولیدپذیری و CLI صحت سریع آزمایش برای فقط فایل‌ها این ندارند. تجربی نتیجه‌گیری برای

۱۱.۲ Quora Question Pairs: ارزیابی: دیتاست

آموزشی جایگزین گزینه دو از یکی است؛ شده انجام Quora Question Pairs دیتاست روی اصلی تجربی ارزیابی دانلود برای اینترنت حجم/دسترسی محدودیت (به دلیل PAN-PC-11 به جای پروژه راهنمای در معرفی شده PAN-PC-11).

قرار مخزن در و می‌شود گرفته نادیده Git در پروژه سیاست طبق ('data/raw/quora/train.csv') خام فایل مخزن در ('outputs/metrics.csv', 'outputs/pair_predictions.csv') تولید شده خروجی‌های فقط نمی‌گیرد؛ شده‌اند. commit

نهایی: نتایج تولید برای اجرا شده دستور

```
python -m plagiarism_engine.cli pairs \
--pairs data/raw/quora/train.csv \
--text-col-a question1 \
--text-col-b question2 \
--label-col is_duplicate \
--limit 5000 \
--threshold 0.25 \
--simhash-threshold 0.75 \
--shingle-size 3 \
```

```
--output outputs/metrics.csv \
--details-output outputs/pair_predictions.csv
```

ارزیابی شده: نمونه ویژگی‌های

5000 جفت‌ها: کل تعداد

(۶۱.۸٪) 3089 (غیرتکراری): ۰ برچسب

(۳۸.۲٪) 1911 (تکراری): ۱ برچسب

است. شده لحاظ بعد بخش در F1 و recall تفسیر در نکته این است؛ نامتوازن برچسب‌ها توزیع

۱۲. Quora Question Pairs جفت (۵۰۰۰ تجربی نتایج)

ذخیره زیر مسیر در و آمده‌اند به دست Quora سؤال جفت ۵۰۰۰ روی 'pairs' دستور واقعی اجرای از زیر نتایج شده‌اند:

outputs/metrics.csv

```
threshold=0.25 | accuracy=0.6288 | precision=0.5316 |
recall=0.2423 | F1=0.3329 | TP=463 FP=408 TN=2681 FN=1448
MinHash | threshold=0.25 | accuracy=0.6290 | precision=0.5348 |
recall=0.2250 | F1=0.3168 | TP=430 FP=374 TN=2715 FN=1481
SimHash | threshold=0.75 | accuracy=0.6410 | precision=0.5603 |
recall=0.2821 | F1=0.3752 | TP=539 FP=423 TN=2666 FN=1372
```

پیاده‌سازی در چون است، شده گزارش یکسان روش سه هر برای ثانیه) ≈ 3.37 runtime_seconds) اجرا زمان جداگانه هرکدام سپس و می‌شود محاسبه جفت‌ها روی مشترک پیمایش یک طی روش سه هر امتیاز فعلی روش هر زمان نه می‌دهد، نشان را جفت ۵۰۰۰ برای شباهت محاسبه کل زمان عدد این می‌شوند؛ آستانه‌گذاری به‌تنهایی. را

نتایج تفسیر

- در (۳۱۶۸ F1 و ۶۲۸۸) برابر در (۶۲۹۰ accuracy است: دقیق جاکارد از خوبی تخمین MinHash بیت ۱۲۸ امضای می‌دهد نشان این هستند. دقیق جاکارد به نزدیک بسیار (۰.۳۳۲۹) برابر حالی در می‌دهد، واقعی جاکارد شباهت از قابل اعتمادی تخمین داده، حجم این برای (num_perm=128) شینگل. کامل مجموعه‌های نه می‌شوند مقایسه کوتاه امضاهای فقط که
- تا ۰.۲۲۵۰ برابر در (۰.۲۸۲۱ recall به‌خاطر عمدتاً (۰.۳۷۵۲)، است کرده ثبت را F1 بالاترین SimHash مشترک موضوع نشانه معمولاً (که پرمعنا و کم تکرار واژه‌های می‌شود باعث TF-IDF وزن دهی (۰.۲۴۲۳). فقط MinHash و جاکارد که حالی در باشند، داشته نهایی اثرانگشت در بیشتری سهم هستند) سؤال دو می‌سجند. را متوالی سه کلمه‌ای شینگل‌های هم‌پوشانی
- یکسان معنای اما متفاوت کاملاً واژگان با اغلب Quora سؤالات (۰.۳). (زیر است پایین روش سه هر recall paraphrasing) جفت‌ها نوع این در ذاتی به‌طور واژگانی هم‌پوشانی بر مبتنی روش‌های شده‌اند؛ بازنویسی بررسی ۱۶ بخش در محدودیت این واقعی نمونه‌های می‌کنند. عمل ضعیف لفظی) هم‌پوشانی بدون معنایی شده‌اند.
- باشد؛ گمراه‌کننده‌ای معیار به‌تنهایی accuracy می‌شود باعث غیرتکراری (۶۱.۸٪) نامتوازن برچسب توزیع است. گزارش این در خط‌لوله دو مقایسه اصلی معیار F1 دلیل همین به

۱۳. خطا تحلیل چارچوب

است: متمرکز اشتباه نوع دو بر خطا تحلیل

- شده‌اند داده تشخیص تکراری به‌اشتباه که غیرتکراری جفت‌های (false positive) کاذب مثبت
- افتاده‌اند قلم از سامانه توسط که تکراری جفت‌های (false negative) کاذب منفی

احتمالی علل است. شده اعمال Quora جفت ۵۰۰۰ روی اجرای از واقعی نمونه‌های با ۱۶ بخش در چارچوب این شده‌اند. رد یا تأیید واقعی نمونه با ۱۶ بخش در و شدند گرفته نظر در فرضیه به‌عنوان واقعی اجرای از پیش زیر

کاذب: مثبت احتمالی علل

- کوچک بسیار شینگل اندازه
- پرتکرار و عمومی واژه‌های
- پایین شباهت آستانه

کاذب: منفی احتمالی علل

- (paraphrasing) سنگین بازنویسی
- کوتاه بسیار متن‌های
- بزرگ بسیار شینگل اندازه
- مشابه معنای با متفاوت واژگان

۱۴. (Reproducibility) بازتولیدپذیری

است: بازتولیدپذیر زیر موارد طریق از پروژه

- MinHash برای (fixed random seed) ثابت تصادفی بذر
- hashlib از استفاده با قطعی هش
- فرمان خط اجرای
- CSV و JSON ذخیره‌شده خروجی‌های
- خودکار تست‌های

تست‌ها: همه اجرای

pytest tests

۱۵. جمع‌بندی

می‌کند. پیاده‌سازی، CLI، بر مبتنی تکراری، به نزدیک اسناد تشخیص کامل موتور یک پروژه این

روش یک SimHash که حالی در است، مناسب بزرگ مقیاس در کاندید تولید برای MinHash + LSH خط‌لوله می‌دهد. ارائه شباهت سریع تخمین برای اثرانگشت بر مبتنی و فشرده

می‌دهد نشان ۱۲ و ۱۱ (بخش‌های Quora Question Pairs دیتاست از واقعی جفت ۵۰۰۰ روی تجربی ارزیابی وزن‌دار SimHash و ۰.۳۳۳) برابر در $F1 \approx 0.317$ می‌دهد ارائه دقیق جاکارد از قابل‌اعتمادی تخمین MinHash برابر در روش سه هر می‌کند. ثبت روش سه میان در را $F1$ (۰.۳۷۵) بهترین بالاتر recall به‌خاطر TF-IDF با می‌سجند را لفظی شباهت چون می‌کنند، عمل ضعیف ۰.۳) زیر recall) سنگین معنایی بازنویسی با جفت‌های است. شده مستند ۱۶ بخش در واقعی نمونه‌های با محدودیت این معنایی؛ شباهت نه

است. شده تکمیل ۵۰۰۰ جفتی واقعی دیتاست یک روی تجربی ارزیابی با و تست، قابل ماژولار، نهایی سامانه

۱۶. واقعی نمونه‌های با جفت سطح خطای تحلیل (Pair-Level Error Analysis)

می‌کند: تولید جفت سطح پیش‌بینی‌های از اختیاری خروجی فایل یک سامانه

outputs/pair_predictions.csv

روی واقعی اجرای از و می‌شود تولید 'details-output' آرگومان از استفاده با و 'pairs' دستور توسط فایل این است: زیر موارد شامل ردیف هر ردیف). (۵۰۰۰ است شده حاصل Quora جفت ۵۰۰۰

- جفت شناسه (pair id)
- دوم متن و اول متن
- بودن تکراری واقعی برچسب
- SimHash و MinHash دقیق، جاکارد شباهت
- روش هر پیش‌بینی
- روش هر خطای شاخص

زمانی کاذب منفی کند؛ پیش‌بینی را ۱ مقدار روش اما باشد • واقعی برچسب که می‌دهد رخ زمانی کاذب مثبت فایل این از واقعی نمونه چند ادامه در کند. پیش‌بینی را • مقدار روش اما باشد ۱ واقعی برچسب که می‌دهد رخ است. شده بررسی

۱۶.۱ کاذب مثبت نمونه‌های (False Positive)

واقعی (=): برچسب ۰.۲۵؛ دو هر آستانه، minhash=۰.۷۷۳، jaccard=۰.۸۳۳) #۰ جفت

A: "What is the step by step guide to invest in share market in india?"

B: "What is the step by step guide to invest in share market?"

• جفت این برای Quora برچسب اما دارند، بالایی بسیار شینگلی هم‌پوشانی و یکسان‌اند تقریباً جمله دو این دوم سؤال که حالی در می‌کند محدود هند بورس بازار به را موضوع «in India» قید چون زیاد به‌احتمال است؛ نمی‌توانند لفظی هم‌پوشانی بر مبتنی روش سه از هیچ‌کدام که است ظریف معنایی تفاوت یک این است. عمومی است. یکسان جمله دو کلمات تمام تقریباً چون دهند، تشخیص

واقعی (=): برچسب ۰.۳۲۰؛ minhash=۰.۳۳۳، jaccard=۰.۳۳۳) #۱۹ جفت

A: "Which is the best digital marketing institution in banglore?"

B: "Which is the best digital marketing institute in Pune?"

<شهر؟> («Which is the best digital marketing institut(e/ion) in») مشترک قالب یک از سؤال دو هر واقعی تفاوت که شهر (نام کلیدی موجودیت اما دارند، مشترک زیادی سه‌کلمه‌ای شینگل‌های و می‌کنند پیروی که است ریسکی همان دقیقاً خطا این می‌کند. عوض را جمله هر از کلمه یک فقط می‌کند، تعیین را سؤال دو وقتی حتی می‌کنند تولید بالایی شینگلی هم‌پوشانی تکراری نوشتاری قالب‌های بود: شده پیش‌بینی ۱۳ بخش در است. متفاوت جمله اصلی موجودیت

۱۶.۲ کاذب منفی نمونه‌های (False Negative)

واقعی (=): برچسب ۰.۵۹۴؛ minhash=۰.۰، simhash=۰.۰، jaccard=۰.۰) #۷ جفت

A: "How can I be a good geologist?"

B: "What should I do to be a great geologist?"

و جاکارد («what should i» برابر در «how can i») ندارد وجود جمله دو بین مشترکی سه کلمه‌ای شینگل هیچ واژه به‌خاطر (۰.۵۹۴)، هم‌پوشانی مقداری TF-IDF وزن‌دهی با SimHash می‌زنند. تخمین صفر دقیقاً MinHash می‌شود. رد و می‌ماند ۰.۷۵ آستانه زیر همچنان اما می‌دهد، تشخیص («geologist» مشترک

واقعی=۱): برچسب (simhash=۰.۷۱۹، minhash=۰.۰، jaccard=۰.۱۱) #۱۱ جفت

A: "How do I read and find my YouTube comments?"

B: "How can I see all my Youtube comments?"

نزدیک‌ترین SimHash دارد. وجود («Youtube»/«comments») مشترک محتوایی کلمه یک تنها قبل، نمونه مشابه می‌خورد. شکست هم باز اما ۰.۷۵) برابر در (۰.۷۱۹) است آستانه از عبور به روش

را **لفظی/واژگانی** شباهت آن‌ها می‌دهند: نشان را روش سه هر مشترک اصلی محدودیت بالا نمونه دو هر شده‌اند، بیان یکسان مفهوم اما متفاوت کاملاً واژگان با که جفت‌هایی برای **معنایی** شباهت نه می‌سجند، روی همچنان وزن‌دهی چون می‌رسد، تشخیص آستانه به به‌سختی هم TF-IDF با وزن‌دار SimHash حتی نیازمند محدودیت این رفع کند. مرتبط هم به را مترادف‌ها نمی‌تواند و شده بنا مشترک واژگان هم‌پوشانی است. پروژه این محدوده از خارج که است متن) های embedding (مثل معنایی بازنمایی

(Bonus) امتیازی ویژگی‌های ۱۷.

پیاده‌سازی 'src/plagiarism_engine/bonus.py' مستقل ماژول در تکمیلی ایده سه الزامی، مسیر دو بر علاوه به‌طور و نمی‌دهد تغییر را ('pairs'، 'corpus'، 'compare') CLI الزامی دستور سه رفتار ماژول این است. شده است. شده آزموده 'tests/test_bonus.py' در مستقل

LSH پارامترهای خودکار تنظیم ۱۷.۱

باند) هر در سطر باند، (تعداد جفت، 'num_bands' دستی انتخاب به‌جای 'find_adaptive_lsh_params' تابع فقط جست‌وجو می‌کند. جست‌وجو باشد نزدیک‌تر هدف شباهت آستانه یک به آن S-curve آستانه که را بخش‌پذیری به نیاز 'split_signature_into_bands' زیرا می‌کند، بررسی را امضا طول دقیق مقسوم‌علیه‌های دارد. دقیق

فارسی سبک بن‌واژه‌ساز ۱۷.۲

'نمی' ('می'، استمرار فعل پیشوندهای و 'ان') 'های'، 'ها'، رایج جمع پسوندهای 'persian_lemmatize' تابع دیده یکسان‌تر شینگل‌سازی در «دانشجو» و «دانشجویان» (مانند واژه یک صرفی صورت‌های تا می‌کند حذف را است. شفاف و قاعده‌محور اکتشاف یک صرفاً نیست؛ کامل صرفی تحلیل‌گر یک ابزار این شوند.

کاراکتری (n-gram +) (کلمه ترکیبی سیم‌هش ۱۷.۳)

اثرانگشت محاسبه در نیز را کلمه هر کاراکتری های n-gram کلمه‌ای، توکن‌های بر علاوه 'hybrid_simhash' تابع کلمه یک سه کاراکتری های n-gram از زیادی بخش هنوز اشتباه‌تایپ شده یا جابه‌جا حرف چند چون می‌کند. دخیل است. مقاوم‌تر املائی غلط‌های برابر در کلمه، بر مبتنی استاندارد SimHash به نسبت روش این می‌کند، حفظ را

اختیاری CLI دستور ۱۷.۴

```
python -m plagiarism_engine.cli bonus-eval \
  --pairs data/sample_corpus/sample_pairs.csv \
  --text-col-a text_a \
  --text-col-b text_b \
  --label-col label \
  --threshold 0.1 \
  --simhash-threshold 0.5 \
  --output outputs/bonus_metrics.csv
```

نمونه مجموعه روی می‌کند. مقایسه هم کنار را ترکیبی SimHash و استاندارد SimHash معیارهای دستور این و کامل رهگیری می‌کند؛ ثبت استاندارد نسخه به نسبت بالاتری F1-score ترکیبی SimHash پروژه، کوچک 'notebooks/exploration.ipynb' در امتیازی، بخش توابع تک‌تک اجرای نمونه‌های همراه به نتیجه، این تفسیرشده است. موجود